Cassio S. Almeida



Arquiteto de IA · CAIO (Chief AI Officer) · Technical Solutions Advisor · CTO

Guaíba, RS · remoto no Brasil, híbrido em Porto Alegre +55 (51) 98411-0563

cassio.a001@gmail.com linkedin.com/in/cassioalmeida79 Baixar PDF

Versão atual: drive.google.com/file/d/16PbA0OF_jXUT9kSu3BFGVJ47iVIvwra8/view

Um agente vale pelo gate, não pela persona.

Trinta anos em tecnologia, desde 1996. Mais de uma década liderando engenharia, produto e operação em bancos, meios de pagamento, SaaS, ERPs e indústria, e os últimos anos desenhando arquitetura de IA para ambiente corporativo regulado.

Pedir a um modelo que seja cuidadoso não é verificável. Teste com asserção, validação de contrato e comparação com baseline são. O agente propõe, o verificador decide, e cada decisão deixa evidência que se audita seis meses depois.

Liderança de IA, no perfil de CAIO (Chief AI Officer): estratégia, adoção e governança de IA em escala corporativa, do letramento dos times à verificação automática da saída dos agentes, com LGPD, ISO 27001 e ISO 42001 como moldura de risco.

299	123	120+	-45%
verificadores mecânicos em 34 gates	massas sintéticas com gabarito	pessoas no maior time liderado	no custo de cloud com FinOps

01 · ARQUITETURA DE IA

Cinco decisões de arquitetura e o que cada uma custou

Construído na CSA Tech, consultoria própria em engenharia e IA aplicada, em operação desde 2020. Demonstrações usam clientes e dados fictícios.

Verificação

Verificador mecânico em vez de LLM julgando LLM

PROBLEMA

Usar outro modelo como juiz repete o problema: o juiz erra como o avaliado, não dá o mesmo veredito duas vezes e não explica por que aprovou.

DECISÃO

Todo agente herda o mesmo núcleo de verificação. Cada verificador é uma asserção binária e offline, sem chamada de modelo. Reprovou, volta com o item exato; três reprovações no mesmo item escalam para uma pessoa.

TRADE-OFF

O gate só cobre o que se especifica. O resto não finge estar coberto: vira ressalva declarada ou decisão humana. Troco cobertura aparente por veredito reprodutível.

EVIDÊNCIA

34 gates e 299 verificadores. Cada execução registra entradas, versão do agente, versão do gate, resultado por verificador e hash do artefato.

Plataforma

Orquestração e retroaprendizagem sem automodificação

PROBLEMA

Um catálogo de agentes precisa escolher o agente certo, saber o que cada um faz e melhorar com o uso. Agente que reescreve o próprio comportamento impede dizer, numa auditoria, sob qual versão um artefato foi gerado.

DECISÃO

Comportamento versionado em git, mudando só por revisão humana. O aprendizado vira proposta de mudança. Orquestrador de seleção por frente, orquestrador de monitoramento, agente que propõe ajuste de acurácia e rastro de ponta a ponta de cada execução.

TRADE-OFF

Abro mão de adaptação em tempo real. Cada artefato aponta para a versão exata que o produziu, e cada melhoria tem autor e aprovação.

EVIDÊNCIA

Os gates que verificam a própria plataforma têm gabarito, com precisão 1,00 e recall 1,00 sobre 22 verificadores, e linha de base congelada que acusa queda.

Medição

Massas sintéticas com gabarito, precisão e recall

PROBLEMA

Toda POC de IA termina na pergunta "o agente está bom?". Sem linha de base, a resposta é opinião.

DECISÃO

Massas sintéticas por mercado e stack, cada uma com gabarito dos defeitos plantados, e um aferidor de precisão, recall e lacuna declarada. A massa não é o produto; o gabarito é. Nenhum dado real entra, nem anonimizado.

TRADE-OFF

Dado sintético não reproduz todo o ruído de um sistema real. Aceito para poder medir, repetir e mostrar sem expor ninguém, e declaro o que fica de fora.

EVIDÊNCIA

123 massas, com regressão que compara cada rodada com a anterior. Última rodada sem nenhuma queda.

Legado

Modernização com rastreabilidade de regra a evidência

PROBLEMA

Migração de COBOL, ColdFusion, PL/SQL ou Java legado falha entre os documentos. Cada artefato parece bom sozinho, e a regra que está no mapa some no backlog.

DECISÃO

Sete estágios: arqueologia, cartografia, documentação, aprovação, tradução em histórias, construção e equivalência. Leitura determinística antes do agente, caracterização antes da mudança, lotes com reversão. Um gate confere as emendas entre estágios.

TRADE-OFF

Mais lento que pedir a um agente que reescreva o sistema. Em troca, cada regra nova tem origem com arquivo e linha no legado, e a equivalência é provada.

EVIDÊNCIA

Agentes por estágio, gates por stack legada e gate de rastreabilidade. Nenhum estágio avança sem aprovação do gerente de produto e do arquiteto.

Portabilidade

Arquitetura agnóstica de fornecedor

PROBLEMA

Empresa regulada não aceita ficar presa a um provedor de modelo.

DECISÃO

Agente em markdown versionado, verificador em código puro, inferência atrás de gateway, ferramentas por MCP, agente para agente por A2A, identidade por OIDC, observabilidade por OpenTelemetry, execução em contêiner. O agente declara classe de capacidade, nunca nome de modelo.

TRADE-OFF

Recurso exclusivo de um provedor só entra como acelerador opcional. Acelerador pode mudar custo e latência, nunca o artefato nem o veredito.

EVIDÊNCIA

Matriz de conformidade: a mesma tarefa em mais de um provedor precisa dar o mesmo veredito. Azure e OpenAI, GCP e Gemini, AWS, Anthropic, NVIDIA.

02 · IA EM PROJETOS E LETRAMENTO

Levar IA do discurso para o ciclo de desenvolvimento

Como Technical Solutions Advisor em empresas de serviços de tecnologia de Porto Alegre (2025 a 2026), criei e conduzi o programa de adoção de IA (Datum AI First) e atuei nos projetos e POCs de IA da casa. Clientes citados por mercado e porte.

Programa

Programa de adoção de IA na empresa e na oferta

PROBLEMA

IA aparecia na oferta como promessa: sem escopo, sem entregável e sem critério de aceite. Não dava para vender com segurança nem para aprovar a entrega.

DECISÃO

Tratar IA como capacidade de entrega, não como tema. Defini posicionamento, portfólio de ofertas por etapa do ciclo de software e um modelo de entrega em que toda POC nasce com hipótese mensurável, linha de base e critério de aceite.

TRADE-OFF

Critério de aceite antes de ferramenta atrasa a primeira demonstração. Em troca, evita a POC bonita que ninguém consegue aprovar.

RESULTADO

Oferta de IA com escopo, entregável e aceite, usada em propostas e POCs de grandes contas no Brasil e na América Latina.

Produção

SDLC com agentes em produção

PROBLEMA

Squads de modernização de legado numa plataforma de benefícios e gestão de frotas de grande porte, no Brasil e na França, precisavam entender código antigo, regras escondidas em procedures e integrações antes de mexer.

DECISÃO

Liderei a criação de 118 agentes especializados, 6 servidores MCP e mais de 50 ferramentas MCP, com Claude Code como núcleo. A cadeia em produção desde dez/2025: análise do legado (código, regras em procedures, stacks e integrações), agentes analista e arquiteto, PO que gera épicos, histórias e tarefas no Azure DevOps, Dev por stack, QA de todo o fluxo de testes até o Pull Request e DevOps para CI/CD. Gate humano em cada decisão.

TRADE-OFF

Gate humano em todas as etapas deixa o fluxo menos automático. Em troca, nada chega ao merge sem revisão, e cada decisão fica registrada.

RESULTADO

Medido num caso real: ~25.700 linhas de legado analisadas, 1 bug crítico prevenido antes do merge, conformidade arquitetural 3/3, documentação de 0 para 2 e testes de 0 para 3. Estimado, com baseline declarado: compreensão do legado ~70 a 85% mais rápida, implementação ~50 a 60% e documentação ~70%. Framework de medição com DORA, SPACE e DevEx.

Letramento

Letramento em IA por público

PROBLEMA

Cada público usava IA de um jeito e ninguém tinha critério comum: liderança sem saber o que cobrar, negócio sem saber o que pedir, time técnico sem saber como validar.

DECISÃO

Concebi e conduzi trilhas separadas para lideranças, times de negócio e times técnicos, internamente e em clientes. O fio comum era o mesmo em todas: uso responsável e LGPD, onde IA agrega no trabalho de cada um e como verificar a saída antes de confiar nela. Para times técnicos, concebi, estruturei e ministrei a Trilha de IA de 74h: SDLC com IA, geração e revisão de código e testes, agentes com MCP e RAG, e arquitetura de sistemas com IA.

TRADE-OFF

Três trilhas custam mais para montar e manter que uma palestra única. Em troca, cada público sai com prática aplicável ao próprio trabalho.

RESULTADO

Letramento conduzido para equipes internas e para times de clientes, incluindo telecom e serviços financeiros.

SDLC Agentes no ciclo completo

IA do requisito à entrega

Desenho de soluções com agentes por etapa do ciclo de software: refinamento de requisitos, arquitetura, código, revisão, testes, pipeline e documentação, com verificação da saída de cada etapa.

Legado Modernização

Migração e obsolescência com IA

Soluções e POCs de migração de COBOL, ColdFusion e Java obsoleto para stacks atuais, em meios de pagamento, benefícios e seguros: levantamento de regras de negócio do legado, plano em lotes e prova de equivalência. POCs de COBOL para Java 17 com agentes numa processadora de pagamentos global e num banco digital; em demo, 8 programas analisados em cerca de 7 minutos e backlog técnico em cerca de 10 minutos. Projeto real de ColdFusion e Sybase para Java e Oracle.

COE de Qualidade QA com IA

IA aplicada a testes e qualidade

POC de IA para centro de excelência de qualidade em operadora de telecom de grande porte: geração e revisão de casos de teste, rastreabilidade por regra e relatório de cobertura.

COE de IA · Automação Negócio

Copilotos e automação de processos

Copiloto comercial para banco de grande porte e automação de processos de negócio com IA generativa, sempre com hipótese mensurável e linha de base definidas antes da construção.

Ambientes regulados: BACEN (Res. CMN 4.893 e 4.557), PCI-DSS, LGPD, GDPR, SOC 2, ISO 27001 (implantação numa adquirente) e consultoria de implantação de ISO 27001 e ISO 42001.

Ferramentas e stacks: Claude Code e API Anthropic, Cursor, Gemini CLI; MCP, A2A, LangGraph, LangChain; Azure OpenAI, Azure AI Search (busca híbrida e semantic ranker), Azure AI Foundry, Copilot Studio, Microsoft Fabric; Vertex AI, Vertex AI Vector Search, Gemini Enterprise, ADK, BigQuery, Spanner; ChromaDB e NeMo Guardrails em POC; Azure DevOps, GitHub Actions, Docker, Kubernetes, Terraform; Python, Java 17, Spring Boot 3.

03 · PRÉ-VENDAS E SOLUÇÕES

Ganhar a conta com proposta que se defende

Discovery, desenho da solução, proposta técnica e comercial, precificação, dimensionamento de squad, POC e defesa técnica junto ao cliente.

Datum & MG Info 2025 – 2026

Technical Solutions Advisor

Frente de pré-vendas em grandes contas

Liderei as propostas técnicas, RFPs e desenhos de solução orientados a valor, com dimensionamento de squad e formação de preço, e conduzi POCs e squads gerenciadas.

- Grandes contas nacionais de varejo, bancos, seguros, crédito, benefícios e telecom
- Ponte entre estratégia de negócio, arquitetura e parceiros de cloud

ALCANCE

Projetos em Brasil, México, Colômbia, Chile, Argentina, Uruguai e França.

Accenture 2017 – 2019 Gerente de QA e TI

Virada e renovação de um contrato crítico

Contrato com cooperativa de crédito de grande porte, RS. Desenhei a proposta de serviços, dimensionei as equipes e fiz a defesa técnica na renovação e na ampliação do escopo, liderando mais de 120 pessoas.

RESULTADO MEDIDO

Contrato renovado por mais 2 anos, SAFe em 16 squads, eficiência e qualidade das entregas +25%.

04 · LIDERANÇA DE TECNOLOGIA

Liderar a casa: time, arquitetura, custo e governança

Fast2Mine 2023 – 2025 CTO

Tecnologia para operar em quatro continentes

Estratégia tecnológica global, produtos para expansão internacional, CI/CD, DevOps, LGPD, GDPR, SOC 2, ISO 27001 e nuvem AWS e GCP com FinOps (Vertex AI, BigQuery, Spanner, Kubernetes e Terraform).

RESULTADO MEDIDO

Cloud -45%, estrutura -30% com quatro lideranças promovidas, operação em mais de 9 países.

Creare Sistemas 2025

Diretor de Produtos (CPO)

Área de Produtos montada do zero

Empresa nacional de grande porte, Canoas, RS. PMs, POs, UX e QA, roadmaps orientados a dados e discovery contínuo com OKRs de produto.

RESULTADO MEDIDO

Retrabalho -40%, NPS +25%, eficiência operacional +35%.

Agibank 2021 – 2022

Chapter Leader, Core Banking

Tribos de conta PJ, empréstimos e cartões

Banco nacional de médio porte, Porto Alegre. Mais de 96 profissionais em tribos e squads, com coaching de gestores e formação de liderança intermediária.

RESULTADO MEDIDO

Fornecedores e ferramentas -25%, escalabilidade das entregas +40%.

Bling (Locaweb) · Dock 2020 – 2023

Gerente de TI

Reestruturação e recuperação de entrega

No SaaS, 50 pessoas reorganizadas em tribos, squads, QA e produto, e criação do ITOps. Na fintech de pagamentos, projetos parados recuperados com Scrum, Kanban e SAFe.

RESULTADO MEDIDO

Performance +30% e turnover -25%; projetos recuperados em 11 meses, entrega -25% no tempo médio.

COMO EU TRABALHO COM IA

O agente propõe, o verificador decide

É isso que separa uma demonstração de um sistema que a empresa pode auditar, assumir e reverter.

O mesmo desenho vale para produto, proposta, código, teste, pipeline e entrega: definir o critério antes, produzir, verificar mecanicamente e guardar a evidência.

entrada	tarefa e critério de aceite definidos antes
agente	produz a saída
gate	asserção, contrato, baseline
decisão	aprova ou reprova, sem julgamento de modelo
evidência	pacote versionado, auditável e reversível

FORA DA OPERAÇÃO

Palestras, formação de gente e conselho

Palestras

IA aplicada e engenharia de software no TDC, Agile Trends e DevOps Days, em universidades e em empresas de médio e grande porte de seguros e meios de pagamento.

Treinamento e docência

Trilhas corporativas sob medida para times de clientes e equipes internas. Docência em cursos técnicos e superiores de TI, incluindo Escolas e Faculdades QI.

Conselho e investimento

Presidente do PUC Angels/RS de mai/2025 a fev/2026, conselheiro e investidor anjo. Formação de conselheiros PFCC pela Board Academy.

Formação

- MBA E-commerce e Negócios Digitais, PUCRS
- MBA Gestão da Inovação Corporativa
- Sistemas de Informação, ULBRA

Certificações

- SAFe 4.6 (Leading SAFe e Agilist)
- KSD (Kanban University)
- ACC, PACC e PALC (Agile Institute Brazil)
- SMAC e SPOAC; CLF e PBB (Caroli.org)
- CTFL e CTFL-AT (BSTQB)
- CMC (ABECS/FEBRABAN)

Idiomas e formato

- Inglês intermediário, espanhol básico
- CLT, PJ ou cooperado
- Alocação PJ via CSA Tech

Números do método (34 gates, 299 verificadores, 66 agentes, 123 massas) conforme o estado medido em 27 de outubro de 2026; precisão e recall sobre 22 verificadores e a regressão das massas são da medição de 23 e 24 de setembro de 2026; experiência em produção atualizada em 2 de outubro de 2026. Clientes citados por mercado, porte e localização. Versão sempre atualizada neste link: https://drive.google.com/file/d/16PbA0OF_jXUT9kSu3BFGVJ47iVIvwra8/view

---

Cassio S. Almeida · +55 (51) 98411-0563 · cassio.a001@gmail.com