

Cassio Almeida

Arquiteto de IA · Technical Solutions Advisor · CTO

Guaíba, RS · remoto no Brasil, híbrido em Porto Alegre +55 (51) 98411-0563

cassio.a001@gmail.com [linkedin.com/in/cassioalmeida79](https://www.linkedin.com/in/cassioalmeida79) [Baixar PDF](#)

Versão atual: drive.google.com/file/d/16PbA0OF_jXUT9kSu3BFGVJ47iVlwwra8/view



Um agente vale pelo **gate**, não pela persona.

Trinta anos em tecnologia, desde 1996. Mais de uma década liderando engenharia, produto e operação em bancos, meios de pagamento, SaaS, ERPs e indústria, e os últimos anos desenhando arquitetura de IA para ambiente corporativo regulado.

Pedir a um modelo que seja cuidadoso não é verificável. Teste com asserção, validação de contrato e comparação com baseline são. O agente propõe, o verificador decide, e cada decisão deixa evidência que se audita seis meses depois.

183 verificadores mecânicos em 20 gates	118 massas sintéticas com gabarito	120+ pessoas no maior time liderado	-45% no custo de cloud com FinOps
---	--	---	---

01 · ARQUITETURA DE IA

Cinco decisões de arquitetura e o que cada uma custou

Construído na CSA Tech, consultoria própria em engenharia e IA aplicada, em operação desde 2020. Demonstrações usam clientes e dados fictícios.

Verificação	PROBLEMA	Usar outro modelo como juiz repete o problema: o juiz erra como o avaliado, não dá o mesmo veredito duas vezes e não explica por que aprovou.
	DECISÃO	Todo agente herda o mesmo núcleo de verificação. Cada verificador é uma asserção binária e offline, sem chamada de modelo. Reprovou, volta com o item exato; três reprovações no mesmo item escalam para uma pessoa.
	TRADE - OFF	O gate só cobre o que se especifica. O resto não finge estar coberto: vira ressalva declarada ou decisão humana. Troco cobertura aparente por veredito reproduzível.
	EVIDÊNCIA	20 gates e 183 verificadores. Cada execução registra entradas, versão do agente, versão do gate, resultado por verificador e hash do artefato.

Plataforma	PROBLEMA	Um catálogo de agentes precisa escolher o agente certo, saber o que cada um faz e melhorar com o uso. Agente que reescreve o próprio comportamento impede dizer, numa auditoria, sob qual versão um artefato foi gerado.
	DECISÃO	Comportamento versionado em git, mudando só por revisão humana. O aprendizado vira proposta de mudança. Orquestrador de seleção por frente, orquestrador de monitoramento, agente que propõe ajuste de acurácia e rastro de ponta a ponta de cada execução.
	TRADE - OFF	Abro mão de adaptação em tempo real. Cada artefato aponta para a versão exata que o produziu, e cada melhoria tem autor e aprovação.
	EVIDÊNCIA	Os gates que verificam a própria plataforma têm gabarito, com precisão 1,00 e recall 1,00 sobre 22 verificadores, e linha de base congelada que acusa queda.

Medição	PROBLEMA	Toda POC de IA termina na pergunta "o agente está bom?". Sem linha de base, a resposta é opinião.
	DECISÃO	Massas sintéticas por mercado e stack, cada uma com gabarito dos defeitos plantados, e um aferidor de precisão, recall e lacuna declarada. A massa não é o produto; o gabarito é. Nenhum dado real entra, nem anonimizado.
	TRADE - OFF	Dado sintético não reproduz todo o ruído de um sistema real. Aceito para poder medir, repetir e mostrar sem expor ninguém, e declaro o que fica de fora.
	EVIDÊNCIA	118 massas, com regressão que compara cada rodada com a anterior. Última rodada sem nenhuma queda.

Legado Modernização com rastreabilidade de regra a evidência	PROBLEMA	Migração de COBOL, ColdFusion, PL/SQL ou Java legado falha entre os documentos. Cada artefato parece bom sozinho, e a regra que está no mapa some no backlog.
	DECISÃO	Sete estágios: arqueologia, cartografia, documentação, aprovação, tradução em histórias, construção e equivalência. Leitura determinística antes do agente, caracterização antes da mudança, lotes com reversão. Um gate confere as emendas entre estágios.
	TRADE - OFF	Mais lento que pedir a um agente que reescreva o sistema. Em troca, cada regra nova tem origem com arquivo e linha no legado, e a equivalência é provada.
	EVIDÊNCIA	Agentes por estágio, gates por stack legada e gate de rastreabilidade. Nenhum estágio avança sem aprovação do gerente de produto e do arquiteto.

Portabilidade Arquitetura agnóstica de fornecedor	PROBLEMA	Empresa regulada não aceita ficar presa a um provedor de modelo.
	DECISÃO	Agente em markdown versionado, verificador em código puro, inferência atrás de gateway, ferramentas por MCP, agente para agente por A2A, identidade por OIDC, observabilidade por OpenTelemetry, execução em contêiner. O agente declara classe de capacidade, nunca nome de modelo.
	TRADE - OFF	Recurso exclusivo de um provedor só entra como acelerador opcional. Acelerador pode mudar custo e latência, nunca o artefato nem o veredito.
	EVIDÊNCIA	Matriz de conformidade: a mesma tarefa em mais de um provedor precisa dar o mesmo veredito. Azure e OpenAI, GCP e Gemini, AWS, Anthropic, NVIDIA.

Levar IA do discurso para o ciclo de desenvolvimento

Como Technical Solutions Advisor em empresas de serviços de tecnologia de Porto Alegre (2025 a 2026), criei e conduzi o programa de adoção de IA (Datum AI First) e atuei nos projetos e POCs de IA da casa. Clientes citados por mercado e porte.

Programa Programa de adoção de IA na empresa e na oferta	PROBLEMA	IA aparecia na oferta como promessa: sem escopo, sem entregável e sem critério de aceite. Não dava para vender com segurança nem para aprovar a entrega.
	DECISÃO	Tratar IA como capacidade de entrega, não como tema. Defini posicionamento, portfólio de ofertas por etapa do ciclo de software e um modelo de entrega em que toda POC nasce com hipótese mensurável, linha de base e critério de aceite.
	TRADE - OFF	Critério de aceite antes de ferramenta atrasa a primeira demonstração. Em troca, evita a POC bonita que ninguém consegue aprovar.
	RESULTADO	Oferta de IA com escopo, entregável e aceite, usada em propostas e POCs de grandes contas no Brasil e na América Latina.

Produção SDLC com agentes em produção	PROBLEMA	Squads de modernização de legado numa plataforma de benefícios e gestão de frotas de grande porte, no Brasil e na França, precisavam entender código antigo, regras escondidas em procedures e integrações antes de mexer.
	DECISÃO	Liderei a criação de 118 agentes especializados, 6 servidores MCP e mais de 50 ferramentas MCP, com Claude Code como núcleo. A cadeia em produção desde dez/2025: análise do legado (código, regras em procedures, stacks e integrações), agentes analista e arquiteto, PO que gera épicos, histórias e tarefas no Azure DevOps, Dev por stack, QA de todo o fluxo de testes até o Pull Request e DevOps para CI/CD. Gate humano em cada decisão.
	TRADE - OFF	Gate humano em todas as etapas deixa o fluxo menos automático. Em troca, nada chega ao merge sem revisão, e cada decisão fica registrada.
	RESULTADO	Medido num caso real: ~25.700 linhas de legado analisadas, 1 bug crítico prevenido antes do merge, conformidade arquitetural 3/3, documentação de 0 para 2 e testes de 0 para 3. Estimado, com baseline declarado: compreensão do legado ~70 a 85% mais rápida, implementação ~50 a 60% e documentação ~70%. Framework de medição com DORA, SPACE e DevEx.

Letramento em IA por público	PROBLEMA	Cada público usava IA de um jeito e ninguém tinha critério comum: liderança sem saber o que cobrar, negócio sem saber o que pedir, time técnico sem saber como validar.
	DECISÃO	Concebi e conduzi trilhas separadas para lideranças, times de negócio e times técnicos, internamente e em clientes. O fio comum era o mesmo em todas: uso responsável e LGPD, onde IA agrega no trabalho de cada um e como verificar a saída antes de confiar nela. Para times técnicos, concebi, estruturei e ministrei a Trilha de IA de 74h: SDLC com IA, geração e revisão de código e testes, agentes com MCP e RAG, e arquitetura de sistemas com IA.
	TRADE - OFF	Três trilhas custam mais para montar e manter que uma palestra única. Em troca, cada público sai com prática aplicável ao próprio trabalho.
	RESULTADO	Letramento conduzido para equipes internas e para times de clientes, incluindo telecom e serviços financeiros.

SDLC Agentes no ciclo completo

IA do requisito à entrega

Desenho de soluções com agentes por etapa do ciclo de software: refinamento de requisitos, arquitetura, código, revisão, testes, pipeline e documentação, com verificação da saída de cada etapa.

Legado Modernização

Migração e obsolescência com IA

Soluções e POCs de migração de COBOL, ColdFusion e Java obsoleto para stacks atuais, em meios de pagamento, benefícios e seguros: levantamento de regras de negócio do legado, plano em lotes e prova de equivalência. POCs de COBOL para Java 17 com agentes numa processadora de pagamentos global e num banco digital; em demo, 8 programas analisados em cerca de 7 minutos e backlog técnico em cerca de 10 minutos. Projeto real de ColdFusion e Sybase para Java e Oracle.

COE de Qualidade QA com IA

IA aplicada a testes e qualidade

POC de IA para centro de excelência de qualidade em operadora de telecom de grande porte: geração e revisão de casos de teste, rastreabilidade por regra e relatório de cobertura.

COE de IA · Automação Negócio

Copilotos e automação de processos

Copiloto comercial para banco de grande porte e automação de processos de negócio com IA generativa, sempre com hipótese mensurável e linha de base definidas antes da construção.

Ambientes regulados: BACEN (Res. CMN 4.893 e 4.557), PCI-DSS, LGPD, GDPR, SOC 2, ISO 27001 (implantação numa adquirente) e consultoria de implantação de ISO 27001 e ISO 42001.

Ferramentas e stacks: Claude Code e API Anthropic, Cursor, Gemini CLI; MCP, A2A, LangGraph, LangChain; Azure OpenAI, Azure AI Search (busca híbrida e

semantic ranker), Azure AI Foundry, Copilot Studio, Microsoft Fabric; Vertex AI, Vertex AI Vector Search, Gemini Enterprise, ADK, BigQuery, Spanner; ChromaDB e NeMo Guardrails em POC; Azure DevOps, GitHub Actions, Docker, Kubernetes, Terraform; Python, Java 17, Spring Boot 3.

03 · PRÉ-VENDAS E SOLUÇÕES

Ganhar a conta com proposta que se defende

Discovery, desenho da solução, proposta técnica e comercial, precificação, dimensionamento de squad, POC e defesa técnica junto ao cliente.

Datum & MG Info 2025 – 2026 Technical Solutions Advisor Frente de pré-vendas em grandes contas Liderei as propostas técnicas, RFPs e desenhos de solução orientados a valor, com dimensionamento de squad e formação de preço, e conduzi POCs e squads gerenciadas. • Grandes contas nacionais de varejo, bancos, seguros, crédito, benefícios e telecom • Ponte entre estratégia de negócio, arquitetura e parceiros de cloud ALCANCE Projetos em Brasil, México, Colômbia, Chile, Argentina, Uruguai e França.	Accenture 2017 – 2019 Gerente de QA e TI Virada e renovação de um contrato crítico Contrato com cooperativa de crédito de grande porte, RS. Desenhei a proposta de serviços, dimensionei as equipes e fiz a defesa técnica na renovação e na ampliação do escopo, liderando mais de 120 pessoas. RESULTADO MEDIDO Contrato renovado por mais 2 anos, SAFe em 16 squads, eficiência e qualidade das entregas +25%.
---	---

04 · LIDERANÇA DE TECNOLOGIA

Liderar a casa: time, arquitetura, custo e governança

Fast2Mine 2023 – 2025 CTO Tecnologia para operar em quatro continentes Estratégia tecnológica global, produtos para expansão internacional, CI/CD, DevOps, LGPD, GDPR, SOC 2, ISO 27001 e nuvem AWS e GCP com FinOps (Vertex AI, BigQuery, Spanner, Kubernetes e Terraform). RESULTADO MEDIDO Cloud -45%, estrutura -30% com quatro lideranças promovidas, operação em mais de 9 países.	Create Sistemas 2025 Diretor de Produtos (CP0) Área de Produtos montada do zero Empresa nacional de grande porte, Canoas, RS. PMs, POs, UX e QA, roadmaps orientados a dados e discovery contínuo com OKRs de produto. RESULTADO MEDIDO Retrabalho -40%, NPS +25%, eficiência operacional +35%.
--	--

Agibank 2021 – 2022

Chapter Leader, Core Banking

Tribos de conta PJ, empréstimos e cartões

Banco nacional de médio porte, Porto Alegre. Mais de 96 profissionais em tribos e squads, com coaching de gestores e formação de liderança intermediária.

RESULTADO MEDIDO

Fornecedores e ferramentas -25%, escalabilidade das entregas +40%.

Bling (Locaweb) · Dock 2020 – 2023

Gerente de TI

Reestruturação e recuperação de entrega

No SaaS, 50 pessoas reorganizadas em tribos, squads, QA e produto, e criação do ITOps. Na fintech de pagamentos, projetos parados recuperados com Scrum, Kanban e SAFe.

RESULTADO MEDIDO

Performance +30% e turnover -25%; projetos recuperados em 11 meses, entrega -25% no tempo médio.

O agente propõe, o verificador decide

É isso que separa uma demonstração de um sistema que a empresa pode auditar, assumir e reverter. O mesmo desenho vale para produto, proposta, código, teste, pipeline e entrega: definir o critério antes, produzir, verificar mecanicamente e guardar a evidência.	entrada	tarefa e critério de aceite definidos antes
	agente	produz a saída
	gate	asserção, contrato, baseline
	decisão	aprova ou reprova, sem julgamento de modelo
	evidência	pacote versionado, auditável e reversível

FORA DA OPERAÇÃO

Palestras, formação de gente e conselho

Palestras IA aplicada e engenharia de software no TDC, Agile Trends e DevOps Days, em universidades e em empresas de médio e grande porte de seguros e meios de pagamento.	Treinamento e docência Trilhas corporativas sob medida para times de clientes e equipes internas. Docência em cursos técnicos e superiores de TI, incluindo Escolas e Faculdades QI.	Conselho e investimento Presidente do PUC Angels/RS de mai/2025 a fev/2026, conselheiro e investidor anjo. Formação de conselheiros PFCC pela Board Academy.
Formação - MBA E-commerce e Negócios Digitais, PUCRS - MBA Gestão da Inovação Corporativa - Sistemas de Informação, ULBRA	Certificações - SAFe 4 Agilist e Leading SAFe - Kanban System Design - CTFL e CTFL-AT (BSTQB)	Idiomas e formato - Inglês intermediário, espanhol básico - CLT, PJ ou cooperado - Alocação PJ via CSA Tech

Números do método conforme o último estado medido, de 23 e 24 de setembro de 2026; experiência em produção atualizada em 2 de outubro de 2026. Clientes citados por mercado,

porte e localização. Versão sempre atualizada neste link:

https://drive.google.com/file/d/16PbA0OF_jXUT9kSu3BFGVJ47iVlwra8/view

Cassio S. Almeida · +55 (51) 98411-0563 · cassio.a001@gmail.com

Portfólio · outubro de 2026